

BigQuery-Geotab Intersection Congestion

Александр Гридин Екатерина Вековцева Марк Колпаков Родион
Гудзь

Содержание

1. Состав команды
2. Данные
3. Введение и постановка задачи
4. EDA
5. Работа с аномалиями и генерация признаков
6. Исследовательский анализ данных
 - 6.1 Визуализация данных
7. Моделирование и интерпретация
8. Выводы и результаты

Состав команды

Проект

BigQuery-Geotab Intersection Congestion

Состав команды

- Александр Гридин
- Екатерина Вековцева
- Марк Колпаков
- Родион Гудзь

Данные

Источник

Датасет **BigQuery-Geotab Intersection Congestion** с соревнования на Kaggle

Описание

Агрегированные показатели регистрации поездок коммерческих транспортных средств, таких как грузовики.

Группировка

Сгруппированы по перекрестку, месяцу, времени суток, направлению движения через перекресток и наличию выходного дня.

Цель проекта

Бизнес-контекст

Оптимизация логистики коммерческого транспорта через анализ времени простоя на перекрёстках

Целевые переменные:

- TotalTimeStopped_p20 - 20-й перцентиль
- TotalTimeStopped_p50 - медиана
- TotalTimeStopped_p80 - 80-й перцентиль

Метрика качества:


- Основная: MAE (Mean Absolute Error)
- Мультитаргетная оценка

EDA — Предобработка целей


Действие

Убраны лишние целевые переменные, чтобы не допустить утечки информации


Intersections with unknown streets names




Матрица корреляции признаков




Train dataset



Weekend



Month



Анализ выбросов и клиппинг

Методы

Проведен анализ выбросов с помощью IQR, Z-оценки, теста Граббса и выполнен клиппинг по квантилю 99,5% для целевой переменной


Наблюдение

Выявлено отсутствие выбросов в координатах и ID


Дополнительно

Добавлены флаги редкого перекрёстка, редких входных и выходных улиц, редких путей


TotalTimeStopped_p20
Выбросов: 78901 (9.2%)




TotalTimeStopped_p50
Выбросов: 40445 (4.7%)




TotalTimeStopped_p80
Выбросов: 6117 (0.7%)




TotalTimeStopped_p20 (после clipping)



TotalTimeStopped_p50 (после clipping)



TotalTimeStopped_p80 (после clipping)



Анализ выбросов и клиппинг — таблица порогов

Клиппинг аномалий - стратегия

Пороги клиппинга:

Переменная	99.5% квантиль	Порог
p20	298 сек	60 сек
p50	375 сек	120 сек
p80	763 сек	300 сек

Эффект клиппинга на распределении

Результат

Удаление менее 0.5% экстремальных значений

Логика порогов:

- Физическая реалистичность
- Сохранение 99.5% данных
- Учёт бизнес-логики

Методы обнаружения сложных аномалий

Isolation Forest:

- Contamination: 1%
- Находит глобальные аномалии
- Быстрая работа на больших данных

Результат сравнения

Только 149 общих аномалий из 4000
найденных

Кодирование категорий и соседние признаки

Кодирование

Target Encoding с кросс-валидацией и Label Encoding для категориальных признаков

Качество после кодирования

После кодирования MAE: $p20 = 2.859844$, $p50 = 9.184705$, $p80 = 17.539677$

Новые пространственные признаки

+3 признака, основанных на ближайших соседях:

- среднее значение таргета у k ближайших соседей
- расстояние до ближайшего соседа

Генерация новых признаков - категориальные

Target Encoding для City:

- K-Fold схема ($k=5$)
- Smoothing = 20
- Отдельно для каждого таргета

Вывод

Существенные различия между городами
- важный признак

Label Encoding для:

- EntryStreetName
- ExitStreetName
- Path
- EntryHeading
- ExitHeading

Генерация новых признаков - геопространственные

На основе ближайших соседей:

- Среднее таргета у 10 соседей
- Расстояние до ближайшего соседа
- Плотность в радиусе 500м

Преимущество

Помогает с новыми перекрёстками
(cold-start)

Метрика расстояния:

- Евклидово расстояние
- Перевод в метры (111 км/градус)

Контекстные признаки

Доменные знания в признаках

1. **Часы пик:** Расстояние до 8:00 и 17:00
2. **Сложные повороты:** Флаг левого поворота/разворота
3. **Редкие маршруты:** Частота Path < 50
4. **Выходные в больших городах:** Комбинация Weekend и City

Распределение углов поворота

Влияние часов пик

Обзор данных

Объём данных:

- Train: 856,000 строк
- Test: 1,800,000 строк
- 30 признаков в исходных данных

Ключевые признаки:

- Координаты (Latitude, Longitude)
- Время (Hour, Month, Weekend)
- География (City, Street names)
- Направления движения

Особенности тестовой выборки:

- На 11% больше уникальных перекрёстков в Test
- Данные разделены в случайном порядке
- Требует учёта cold-start проблемы

Вывод

Необходимы методы, устойчивые к новым перекрёсткам

Географическое распределение перекрёстков

Расположение перекрёстков в США (выборка 100k точек)

- **Наблюдение:** Перекрёстки сосредоточены в крупных городах
- **Вывод:** Важно учитывать региональные особенности
- **Решение:** Добавление признаков на основе кластеризации координат

Распределение данных по месяцам и часам

Распределение по месяцам

- Данные с июня по декабрь
- Нет годовой цикличности

Распределение по часам

- Равномерное покрытие всех часов
- Часы пик: 8:00 и 17:00

Важный вывод

Цикличность по месяцам отсутствует, но есть суточные паттерны

Пропущенные значения и их анализ

Тепловая карта пропущенных значений (missingno)

Пропуски в:

- EntryStreetName
- ExitStreetName

Причина:

- Съезды с магистралей
- Частные территории

Решение

Пропуски не случайны - создаём отдельный признак "Unknown street"

Архитектура модели CatBoost

Параметры модели:

- Задача: MultiRMSE (3 таргета)
- Итерации: 200-600
- Глубина: 5-6
- Learning rate: 0.05-0.1
- Early stopping: 30-50 раундов

Кривая обучения (train/validation)

Найдено

CatBoost лучше ручного кодирования категорий

Категориальные признаки:

- Автоматическая обработка
- Оптимальное кодирование

Динамика качества на разных этапах

Этап	p20 MAE	p50 MAE	p80 MAE	Изменение
Начальный бейзлайн	2.860	9.185	17.540	–
+ Обработка аномалий	2.810	9.050	16.990	-1.7%
+ Новые признаки	2.840	9.120	17.210	+0.8%
+ Отбор признаков	2.850	9.150	17.250	+0.3%

Таблица: Сравнение качества на валидации (подвыборка 200k)

Ключевые выводы

- Обработка аномалий дала наибольший прирост
- Ручная генерация признаков не всегда улучшает качество
- CatBoost хорошо справляется с raw-признаками

Сравнение моделей

Модели

Сравнили 2 разных класса моделей: линейную Ridge и ансамблевую RandomForest.

Результат

По MAE лучше оказалась линейная модель: Ridge MAE = 9.37, RF MAE = 10.28.

Сравнение моделей: Ridge vs Random Forest

Ridge Regression

SHAP важность признаков (Ridge)

- MAE: 9.37
- Интерпретируемость: Высокая

Random Forest

SHAP важность признаков (RF)

- MAE: 10.28
- Интерпретируемость: Средняя

Выбор для интерпретации

Ridge показал лучшее качество и более стабильные SHAP значения

Топ-признаки по влиянию (SHAP анализ)

Общие для обоих моделей:

1. City_te_p80 (кодированный город)
2. Weekend (выходной день)
3. hour_dist_to_peak
4. Latitude, Longitude
5. is_rare_path

Сравнение важности признаков

- Зелёный: Одинаковый знак влияния
- Красный: Разный знак влияния

Наблюдение

17 общих признаков в топ-20 у Ridge и RF

Локальная интерпретация: LIME объяснения

LIME объяснение для Ridge

- Преобладают ОНЕ признаки улиц
- Чёткие линейные эффекты

LIME объяснение для Random Forest

- Более сложные взаимодействия
- Нелинейные эффекты

Вывод по методам интерпретации

SHAP лучше для глобальной интерпретации, LIME - для локальной

Анализ SHAP-эмбеддингов и аномалий

SHAP-эмбеддинги:

- Вектора вкладов каждого признака
- Размерность: число признаков
- Анализ распределений

Важный результат

Удаление SHAP-аномалий увеличило МАЕ с 7.20 до 7.30

Обнаружение аномалий:

- 4% аномальных профилей
- Isolation Forest + Кластеризация
- Удаление ухудшает качество

Характеристики кластеров SHAP-эмбеддингов

Кластер	Размер	Средний таргет	Топ признаки
Cluster 0	24%	6.31 сек	Hour, Weekend, координаты
Cluster 1	18%	8.45 сек	EntryStreetName, is_rare_path
Cluster 2	15%	12.67 сек	City_te, hour_dist_to_peak
Cluster 3	22%	18.92 сек	Все признаки равномерно
Cluster 4	12%	25.34 сек	Редкие улицы, сложные повороты
Cluster 5	9%	32.42 сек	Экстремальные значения всех признаков

Таблица: Характеристики кластеров SHAP-эмбеддингов

Практическое применение

- Кластер 0: Стандартные условия - малые задержки
- Кластер 5: Экстремальные условия - большие задержки
- Добавление cluster как признака дало MAE 7.23 (vs 7.20 baseline)

Эксперимент: SHAP-эмбеддинги как новые признаки

Идея эксперимента:

- Использовать SHAP-эмбеддинги как фичи
- Обучить линейную модель на них
- Сравнить с оригинальными признаками


Сравнение качества моделей


Вывод


SHAP-эмбеддинги - хороший инструмент диагностики, но не замена оригинальным признакам

Результаты (3-fold CV):


- CatBoost (оригинал): 6.79 МАЕ
- Ridge (только SHAP): 9.05 МАЕ
- Ridge (оригинал+SHAP): 9.37 МАЕ







$$f(x) = 9.054$$



$$E[f(X)] = 7.668$$

Выводы по SHAP и кластеризации

Удаление атипичных SHAP-профилей

Очистка наблюдений с атипичным SHAP-профилем ухудшила качество (**MAE 7.204 → 7.305**), поэтому удаление по данному критерию нецелесообразно.

Кластеризация SHAP-эмбеддингов

Кластеризация выявила осмысленную сегментацию (лучший силуэт у **agglomerative**), однако добавление признака **cluster** дало лишь умеренный эффект и не превзошло бейзлайн (**MAE_with_cluster = 7.234**).

SHAP + исходные признаки

Добавление исходных признаков к SHAP-эмбеддингам в линейной модели не улучшило качество, а ухудшило его примерно на **0.32 MAE**. В обоих вариантах качество существенно хуже, чем у исходной модели **CatBoost (MAE = 6.79 ± 0.31)**.

Ключевые результаты проекта

Успехи:

- Обработка аномалий дала +1.7% качества
- CatBoost показал лучшие результаты
- SHAP анализ выявил важные факторы
- Созданы осмысленные кластеры данных

Вызовы:

- Ручные признаки не всегда улучшают качество
- Новые перекрёстки (cold-start)
- Мультитаргетная природа задачи

Финальные метрики

- Лучшая модель: CatBoost с обработкой аномалий
- MAE p50: 9.05 (улучшение на 1.4%)

Дальнейшие направления работы

1. Временные ряды: Учёт последовательности наблюдений
2. Графовые нейросети: Моделирование структуры дорог
3. Ансамбли: Комбинация разных типов моделей
4. Online learning: Адаптация к новым данным

Потенциальный impact

- Снижение времени доставки на 3-5%
- Оптимизация маршрутов в реальном времени
- Прогнозирование заторов на перекрёстках

Спасибо за внимание!

Контакты:

Команда проекта "BigQuery-Geotab Intersection Congestion"
Kaggle Competition